

Analisi Predittiva

CT0429
aa 2022/23
Secondo appello

Febbraio, 2023

Cognome: _____ Nome: _____

Matricola: _____ Firma: _____

ISTRUZIONI (DA LEGGERE ATTENTAMENTE).

Assicuratevi di aver scritto nome cognome e matricola sia qui che sul file Rmarkdown disponibile su Moodle. Il tempo a disposizione per completare tutto l'esame (la parte scritta e la parte su Moodle) è di **90 minuti**.

Nessuno studente può lasciare l'aula fino a che la docente non avrà verificato che tutti abbiano consegnato sia il compito scritto che il file Rmarkdown. Dopo la consegna attendete che la docente dia il permesso di lasciare l'aula.

Question:	1	2	3	4	Total
Points:	5	4	5	4	18
Score:					

Question 1 (5 points)

Il gestore di un data-center desidera costruire un modello per predire il consumo di energia di un data-center in funzione di varie variabili esplicative. Per un campione di 45 giorni ha a disposizione le seguenti informazioni:

- **temp**: la temperatura media giornaliera (in gradi)
- **vento**: la forza del vento che viene incanalato dall'esterno dentro al data-center per raffreddare gli spazi (in nodi)
- **uso**: il numero medio di processi elaborati nella giornata
- **energia**: il consumo di energia, questa è la variabile risposta

Alcune caratteristiche dei dati:

```
summary(df)[c(1,3,4,6),]
```

	temp		vento		uso		energia
Min.	:-4.5	Min.	:0.3	Min.	:22	Min.	:49
Median	: 7.0	Median	:5.0	Median	:29	Median	:59
Mean	: 7.3	Mean	:5.2	Mean	:30	Mean	:60
Max.	:17.4	Max.	:9.7	Max.	:36	Max.	:69

Vengono stimati due modelli lineari:

```
fit1 <- lm(energia ~ temp, data = df)
fit2 <- lm(energia ~ temp+vento+uso, data = df)
```

Il modello fit1 viene usato per stimare degli intervalli di confidenza per due giornate:

```
nd; predict(fit1, newdata = nd, interval = "confidence")

      temp vento uso
g1  7.3    5.2  30
g2 21.0    5.2  30

      [,1] [,2] [,3]
[1,]   NA   NA   NA
[2,]   NA   NA   NA
```

Si confronta poi la bontà di adattamento dei due modelli usando una anova table:

```
anova(fit1, fit2)
```

Analysis of Variance Table

```
Model 1: energia ~ temp
Model 2: energia ~ temp + vento + uso
  Res.Df RSS Df Sum of Sq    F Pr(>F)
1      43 231
2      41  72  2      159 45.3 4.2e-11 ***
---
```


```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Question 2 (4 points)

Un'azienda desidera monitorare i consumi dei dipendenti che hanno una macchina aziendale come benefit. In particolare, per un campione di 61 auto sono state rilevate le seguenti informazioni in un dato lasso di tempo:

- **Cost**: il costo medio del benefit aziendale per l'azienda per quell'auto
- **TA**: il tempo medio di percorrenza casa lavoro per l'utente di un'auto
- **TR**: il tempo medio di percorrenza lavoro casa per l'utente di un'auto

I grafici di dispersione (scatterplot) dei dati sono mostrati nella figura sottostante:



Vengono stimati i due modelli `fit1` e `fit2`:

```
fit1 <- lm(Cost ~ TR, data = df)
fit2 <- lm(Cost ~ TA + TR, data = df)
summary(fit1)$coef
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	10.531	16.4016	0.6421	0.52334611182941315199
TR	6.447	0.5375	11.9938	0.00000000000000002413

```
summary(fit2)$coef
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	7.639	12.8232	0.5957	0.55371703946
TA	6.056	0.9822	6.1656	0.00000007691
TR	-1.528	1.3599	-1.1235	0.26595252412

- i) Come si può interpretare il valore del coefficiente per la variabile `TR` nel modello `fit1`? Il coefficiente risulta significativo?
- ii) Come si può interpretare il valore del coefficiente per la variabile `TR` nel modello `fit2`? Il coefficiente risulta significativo?
- iii) Si può ritenere il modello `fit2` un modello soddisfacente? Che tipo di problematica nei dati si può dedurre dagli output delle stime?

Question 3 (5 points)

Un'azienda che gestisce un sito di vendite di oggetti di seconda mano desidera identificare quali siano i fattori che influenzano il numero di visualizzazioni di un determinato annuncio. Per un campione di 63 annunci vengono registrate le seguenti informazioni:

- **nVis**: il numero di volte in cui l'annuncio è stato visualizzato nelle due settimane successive alla pubblicazione
- **lDesc**: una variabile che indica la lunghezza (in numero di caratteri) della descrizione dell'oggetto

Viene stimato il seguente modello:

```
fit1 <- glm(nVis ~ lDesc, family = "poisson", data = df)

summary(fit1)

[...]
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.127711	0.115698	9.75	<2e-16 ***
lDesc	0.004750	0.000358	13.28	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for poisson family taken to be 1)

Null deviance: 269.132 on 62 degrees of freedom
Residual deviance: 64.619 on 61 degrees of freedom
AIC: 325.9

Number of Fisher Scoring iterations: 4

- i) Si scriva il modello stimato `fit1` in forma estesa:

ii) Come si può interpretare il valore del coefficiente per la variabile `lDesc`?

iii) Cosa si può evincere dai valori dell devianza nulla e residua (Null deviance e Residual deviance) stampati della funzione `summary`? Si spieghi brevemente il ruolo della devianza nei GLM.

Question 4 (4 points)

Un centro studio di ricerche di mercato desidera indagare i fattori che influenzano l'inclinazione delle persone ad essere favorevoli o contrari un determinato quesito referendario. Per un campione di 48 persone si hanno le seguenti informazioni:

- **favor**: l'indicazione se la persona intervistata è a favore (=1) o contraria (=0) al quesito referendario
- **age**: l'età della persona intervistata
- **educ**: il numero di anni passati in percorsi di istruzione scolastica dalla persona intervistata

con cui viene stimato il modello `fit1`

```
fit1 <- glm(favor~age, family = "binomial", data = df); summary(fit1)
```

```
[...]
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	2.5473	1.0057	2.53	0.0113	*
age	-0.0535	0.0187	-2.86	0.0043	**

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 66.208 on 47 degrees of freedom
Residual deviance: 56.381 on 46 degrees of freedom
AIC: 60.38

Number of Fisher Scoring iterations: 4

che viene usato per stimare la probabilità che i soggetti nel dataset `nd` siano a favore del quesito referendario ottenendo una stima puntuale ed un intervallo di confidenza al 98%:

`nd`

	age
Soggetto 1	20
Soggetto 2	80

Infine si stima anche il modello `fit2`

```
fit2 <- glm(favor~age+educ, family = "binomial", data = df)
```


i) Si indichi quale dei due soggetti è più probabile sia a favore del quesito referendario motivando la risposta:

ii) Si spieghi cosa indica la dicitura
(Dispersion parameter for binomial family taken to be 1)
nell'output della funzione `summary`

iii) Si indichi se il valore della devianza per il modello `fit2` è maggiore o minore rispetto a quella del modello `fit1` motivando la risposta: